アセンブリ言語

ABI，バイナリ形式，リンク

情報工学系
権藤克彦

ABI と API

- ABI = application binary interface
  - バイナリコードのためのインタフェース規格.
  - 同じABIをサポートするシステム上では再コンパイル無しで同じバイナリコードを実行できる.
  - コーリングコンベンション，バイトオーダ，アラインメント，バイナリ形式などを定める.
- API = application programming interface
  - ソースコードのためのインタフェース規格.
  - 同じAPIをサポートするシステム上では再コンパイルすれば同じソースコードを実行できる.
  - 例：POSIX や SUSv3 は UNIX の API．システムコール，ライブラリ関数，マクロなどの形式や意味を定めている.

UNIXシステムコールは3年1Qの
システムプログラミングで学ぶ.

オブジェクトファイル，実行可能ファイル

- オブジェクトファイル＝ 拡張子が .o のファイル.
- 実行可能ファイル＝a.out
  - Windowsでは拡張子が .exe のファイル.
- 複数のオブジェクトファイルを1つの実行可能ファイルに合体させることをリンクという.

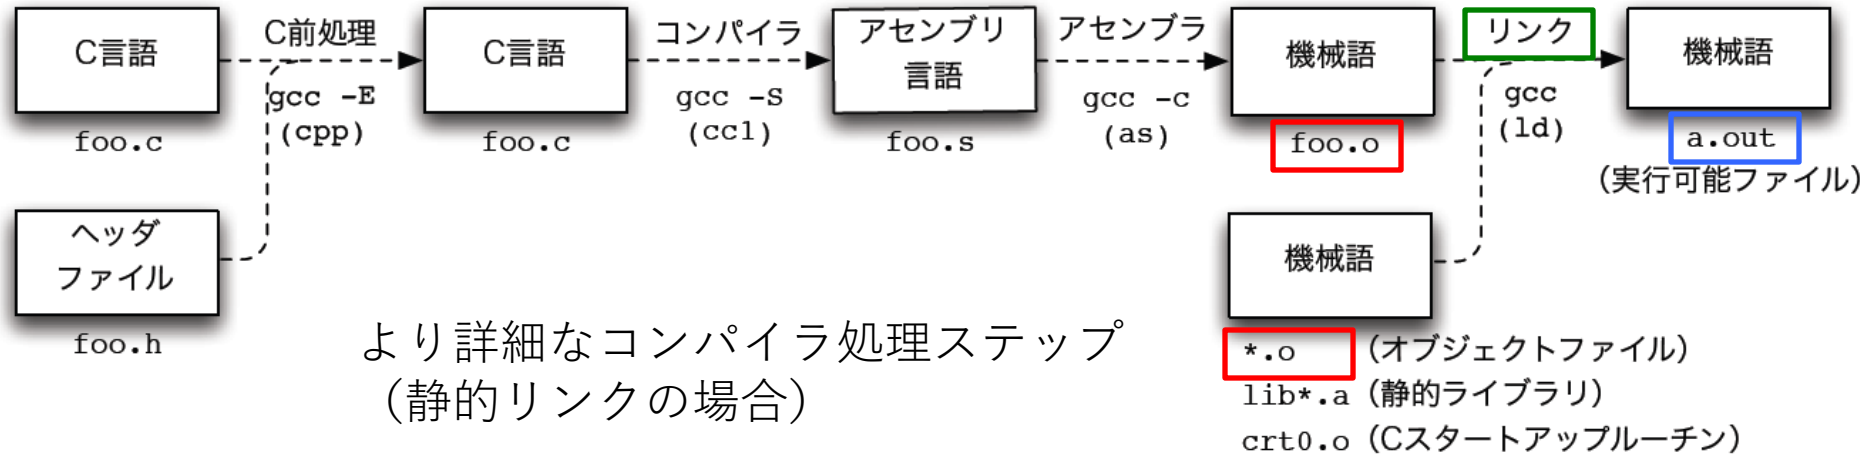

より詳細なコンパイラ処理ステップ
（静的リンクの場合）

全くの別物！

ライブラリ関数とシステムコール（1）

- ライブラリ関数(library function)
  - 例：printf，fopen，malloc
  - （一般に）高レベル．
  - 自分で定義した関数と同様に呼び出せる．
  - （知識があれば）ライブラリ関数を自分でプログラムできる．
- システムコール(system call)
  - 例：write，open，mmap
  - OS（カーネル）が提供するサービスの関数インタフェース．
  - 自分で定義した関数と同様に呼び出せる．
    - ライブラリ関数を経由せず，直接，システムコールを呼び出せる．
  - ライブラリ関数としてはプログラムできない．
    - システムコールの実行にカーネルの特権（CPUの特権モード）が必要なので，システムコールはユーザ空間では実行できない．

printfは内部で
writeを呼び出す．

ライブラリ関数とシステムコール（２）

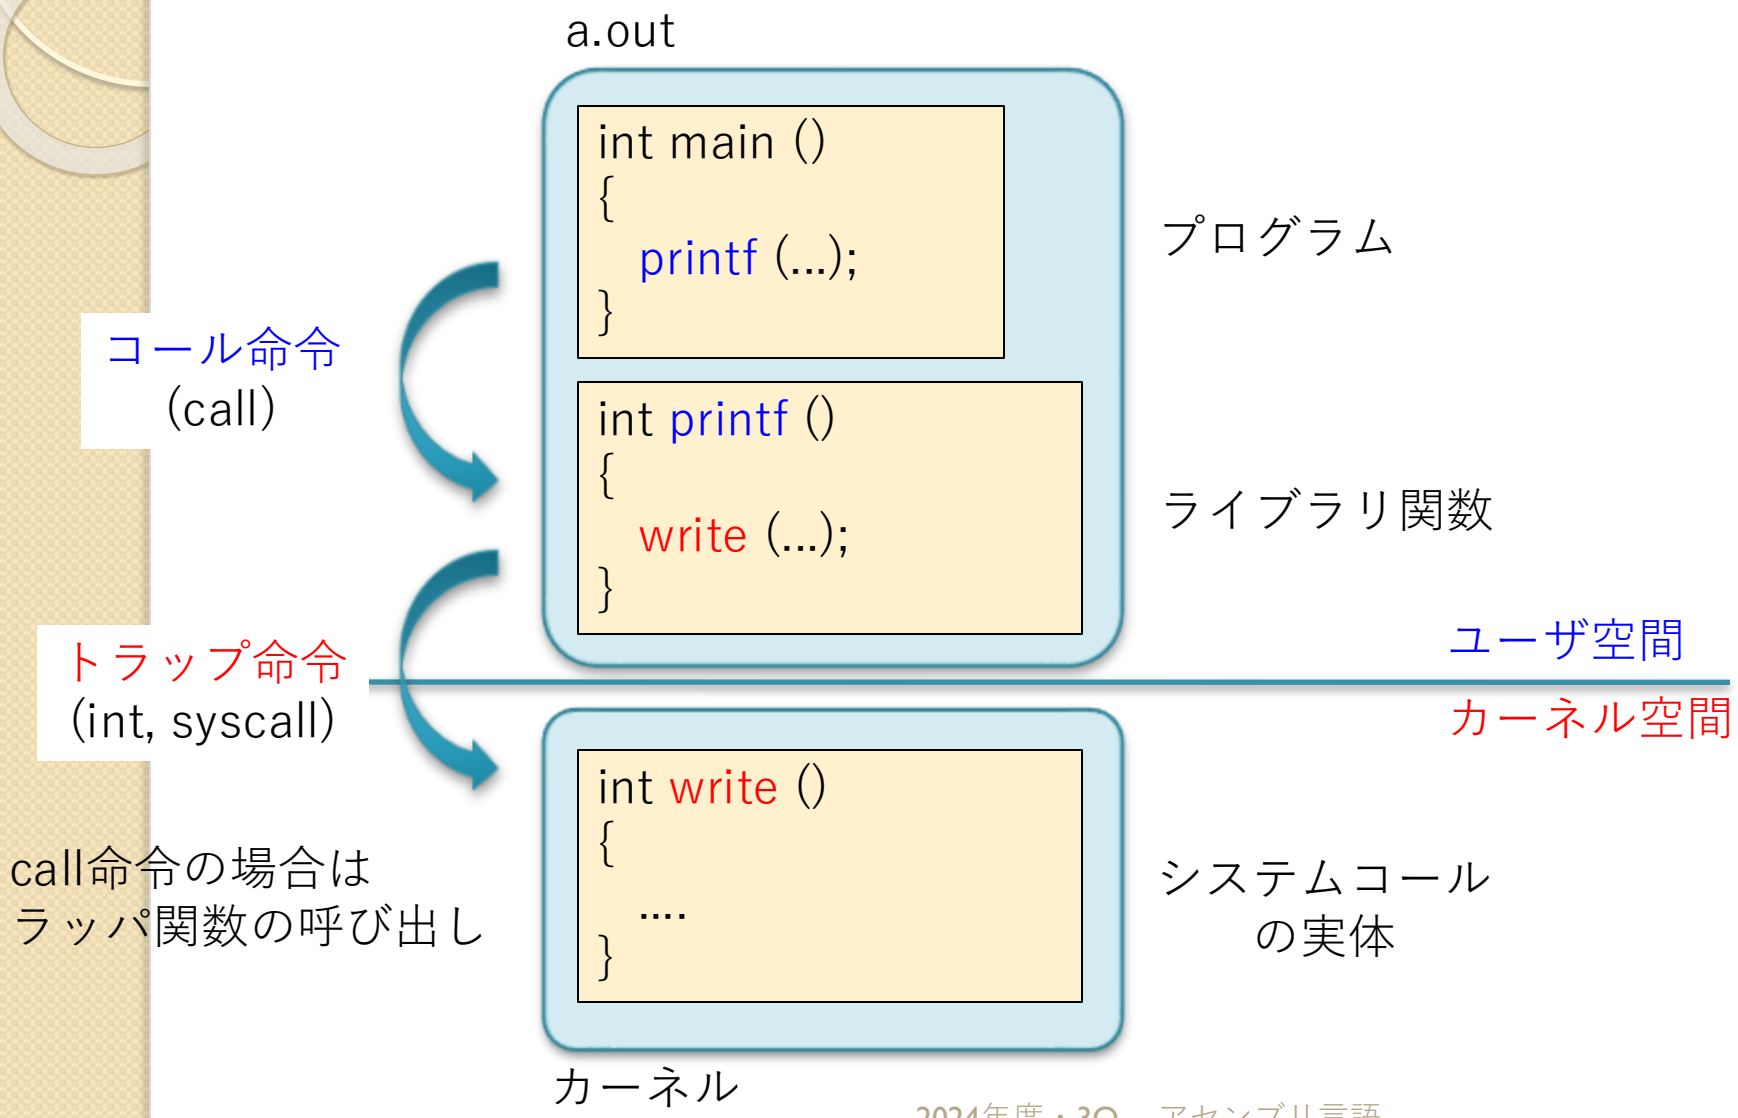

ライブラリ関数とシステムコール（３）

	ライブラリ関数	システムコール
例	printf, fopen, malloc	write, open, mmap
実体の場所	ファイル（例：/usr/lib/libc.a）	OS（カーネル）内部
呼び出す方法	コール命令（例：call）	トラップ命令（例：int）
マニュアル(man)の章	（通常）3章	（通常）2章
呼び出しオーバーヘッド	小さい	大きい
実行時のメモリ空間	ユーザ空間	カーネル空間
実行時間の呼称	ユーザ時間	システム時間

トラップ命令は割り込みの一種.

補足

timeコマンド

- 実行時間を測るコマンド

```
$ time ./a.out
real 0m0.222s
user 0m0.208s
sys 0m0.009s
```

  - user: ユーザ空間でのCPU使用時間
  - sys: カーネル空間でのCPU使用時間
  - real:
    - 実行開始から終了までの経過時間．elapsed time とも言う
    - 対象プロセスが寝ている（ブロックされてる）時間も含む
    - なので，1コア実行なら，real >= user + sys となる
- 時間の精度（解像度）は低い．ミリ秒程度．
- いろんなバージョンあり．↑これはbash内蔵のもの
  - /usr/bin/time だと出力が変わる

バイナリ形式 (binary format)

- オブジェクトファイルや実行可能ファイルの形式.
- いろいろある.

バイナリ形式	説明
Mach-O	macOS用
a.out (assembler output)	古いUNIX用
ELF (executable and linking format)	Linuxなど用
PE (portable executable)	Windows用

- GNU Binutils中のツール（例：objdump）
  - 異なるバイナリ形式に対して使えて便利.
    - cf. readelfコマンドはELF形式のバイナリファイルしか扱えない.
  - ただし，異なるバイナリ形式への変換はできない.

バイナリファイルの種類

- オブジェクトファイル (*.o)
- 実行可能ファイル (a.out)
- ライブラリファイル
  - 静的ライブラリ (lib*.a)
  - 動的ライブラリ（共有ライブラリ） (*.so, *.dll, *.sa, ...)

この授業では
動的ライブラリは
扱いません.

オブジェクトファイル(*.o)

- 再配置可能オブジェクトファイル(relocatable object file)
- セクションからなるバイナリファイル

- 特徴
  - 外部シンボルの参照が未解決.
  - 再配置が可能.

セクション

- セクションはバイナリコードの分割単位.
- 主なセクション
  - .text，.data，.rdata，.bss の４つ.
  - 他には記号表や再配置情報などのセクションがある.
- ヘッダ
  - 「どんなセクションがあるか」という情報を保持.

名前が異なる場合もあるが，
役割は大きくこの4つ.

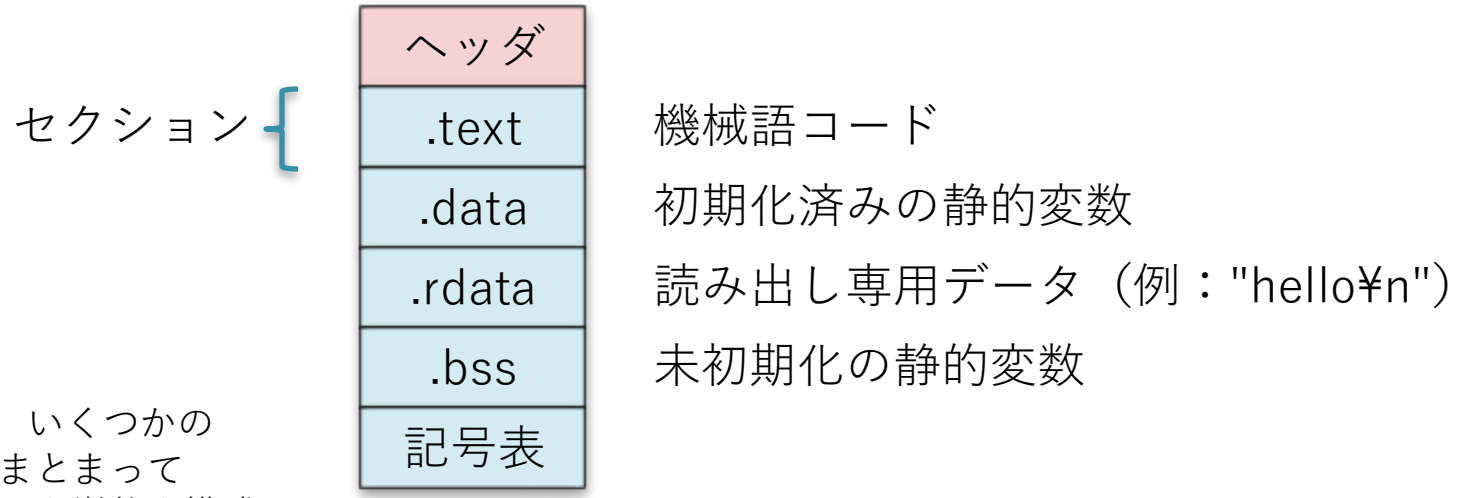

ELF形式では，いくつかの
セクションがまとまって
セグメントという単位を構成.

セクション：objdump –h （１）

読み方は
次スライド参照.

- objdump –h はセクション情報を表示.

```
% objdump -h foo.o
foo.o:     file format mach-o-x86-64
Sections:
Idx Name          Size      VMA               LMA               File off  Algn
  0 .text         00000033  0000000000000000  0000000000000000  00000270  2**4
                  CONTENTS, ALLOC, LOAD, RELOC, CODE
  1 .data         00000004  0000000000000034  0000000000000034  000002a4  2**2
                  CONTENTS, ALLOC, LOAD, DATA
  2 .cstring      00000008  0000000000000038  0000000000000038  000002a8  2**0
                  CONTENTS, ALLOC, LOAD, READONLY, DATA
  3 __LD,__compact_unwind 00000020  0000000000000040  0000000000000040  000002b0  2**3
                  CONTENTS, RELOC, DEBUGGING
  4 .eh_frame     00000040  0000000000000060  0000000000000060  000002d0  2**3
                  CONTENTS, ALLOC, LOAD, READONLY, DATA
```

.rdata は，macOSでは .cstring というセクション名に.

記号表の中身を見るには nm コマンドや objdump --symsを使う.
文字列を見るには string を使う.

セクション：objdump –h （2）

- セクション＝中身＋様々な属性値.

項目	説明
Size	セクションのバイト数
VMA	Virtual Memory Addressの略．実行時の先頭メモリアドレス．再配置に使用.
LMA	Load Memory Addressの略．ロード時の先頭メモリアドレス．通常はVMAと一致.
File off	ファイルオフセット．ファイル先頭からのバイト数.
Align	アラインメント制約．例えば，2**2は2^2を意味し，4バイト境界に要配置.

セクションフラグ	説明
CONTENTS	このセクションには内容がある.
ALLOC	ロード時にメモリ割り当てが必要.
LOAD	ロード時にこのセクションをファイルからロードする必要がある.
RELOC	このセクションは再配置が必要である．再配置情報を含む.
READONLY	このセクション中のデータは読み出し専用である.
CODE	このセクションは機械語コードを含む.
DATA	このセクションはデータ（静的変数）を含む.

外部シンボルの解決

```
% gcc –c main.c
% gcc –c sub.c
% gcc main.o sub.o
% ./a.out
999
%
```

← リンク

- 外部シンボル (external symbol)
  - 自分のファイル中で未定義の変数や関数．例：以下の変数x.
  - 記号ともいう（特に「記号表」(symbol table)という文脈で）
- 外部シンボルの解決
  - ファイルをまたいで，変数や関数の対応関係を調べて，変数名や関数名の参照にメモリアドレスを割り当てること．
  - つまり，未定義の変数や関数を無くす．

main.c

```
#include <stdio.h>
extern int x;
int main (void)
{
    printf ("%d¥n", x);
}
```

sub.c

```
int x = 999;
```

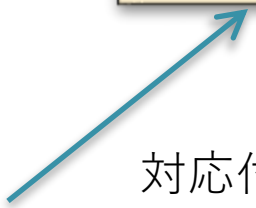

対応付けて，未定義な状態を解決．

外部シンボルの解決

main.c

```
#include <stdio.h>
extern int x;
int main (void)
{
    printf ("%d¥n", x);
}
```

```
% gcc –c main.c
% nm main.o
00000000 T _main
         U _printf
         U _x
%
```

外部シンボル
_printf と _x が
未解決（未定義）

sub.c

```
int x = 999;
```

```
% gcc main.c sub.c
% nm a.out
00001fca T _main
         U _printf
00002014 D _x
%
```

sub.oとリンクして
_xは解決された
（実体と結びついた）.
_printf は未解決.

現在，macOS では –static オプションで
静的リンクした a.outを生成できない.
動的リンクの場合，_printf の解決
（つまりリンク）は実行時にされる.

再配置

- 再配置 (relocation)
  - 仮アドレスを本当のアドレスに修正すること.
- なぜ仮アドレス？
  - リンク時に変数や関数のアドレスは変化するから.
  - オブジェクトファイルでは仮アドレスとし，後で修正可能なようにしてある. （再配置情報として記憶しておく）

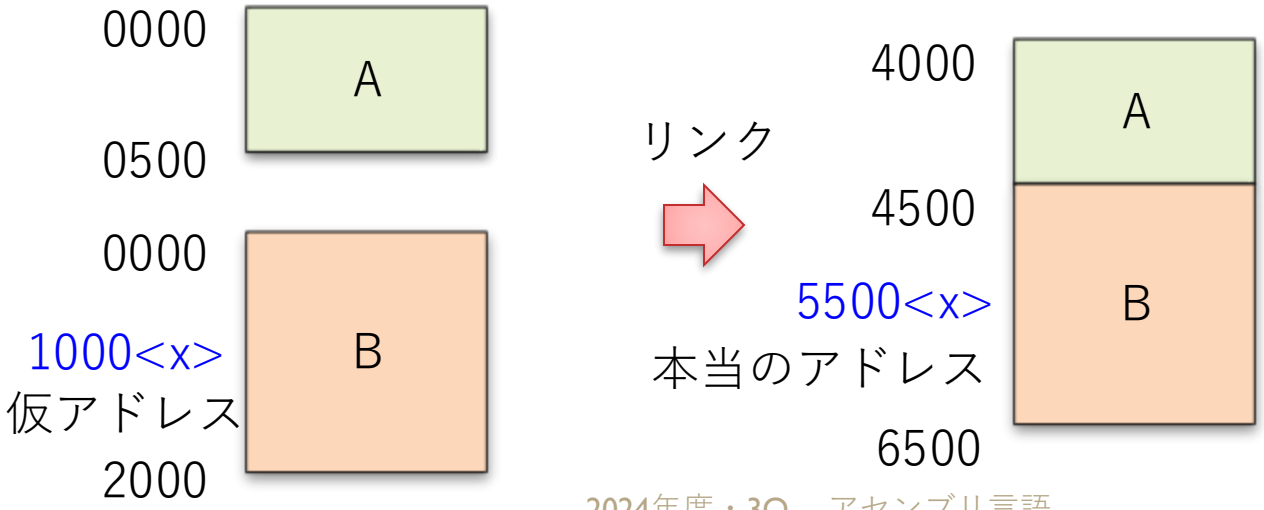

```
static int x = 0xAABBCCDD;
int main ()
{
    return x;
}
```

再配置前(*.o)

```
% gcc –static –c reloc.c
% objdump –Dr reloc.o
Disassembly of section .text:
0000000000000000 <_main>:
 0: 55                    push   %rbp
 1: 48 89 e5              mov    %rsp,%rbp
 4: c7 45 fc 00 00 00 00  movl   $0x0,-0x4(%rbp)
 b: 8b 05 00 00 00 00     mov    0x0(%rip),%eax
        d: DISP32 _x
11: 5d                    pop    %rbp
12: c3                    retq

Disassembly of section .data:
0000000000000014 <_x>:
14: dd cc                 (bad)
```

仮アドレス

再配置情報

実行時ではないと決まらないアドレスもある（例：printf）
→ そのアドレスを入れる場所を事前に決める

再配置後(a.out)

```
% gcc reloc.c
% objdump –Dr a.out
Disassembly of section .text:
0000000100000fa0 <_main>:
 100000fa0: 55                  push   %rbp
 100000fa1: 48 89 e5              mov    %rsp,%rbp
 100000fa4: c7 45 fc 00 00 00 00 movl   $0x0,-0x4(%rbp)
 100000fab: 8b 05 4f 00 00 00    mov    0x4f(%rip),%eax
 100000fb1: 5d                  pop    %rbp
 100000fb2: c3                  retq

Disassembly of section .data:
0000000100001000 <_x>:
 100001000: dd cc                (bad)
```

本当の（相対）アドレス

0x4F + 0xFB1 = 0x1000

リンク（1）

- リンク(link)
  - オブジェクトファイル(*.o)やライブラリファイルを結合して，1つの実行可能ファイル(a.out)にすること．
  - リンカ（コンパイラの一部，ld）が実行処理．
- アドレスの調整が必要．
  - 外部シンボルの解決や再配置などを行って調整する．

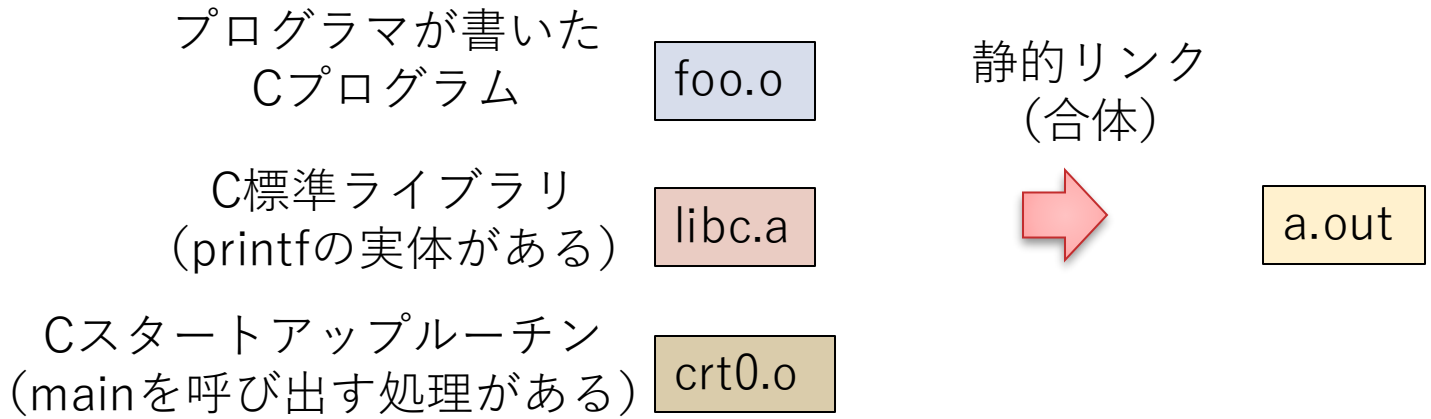

リンク（2）

- リンクはセクションごとにマージする．
  - 当然，アドレス解決と再配置を行いながら．

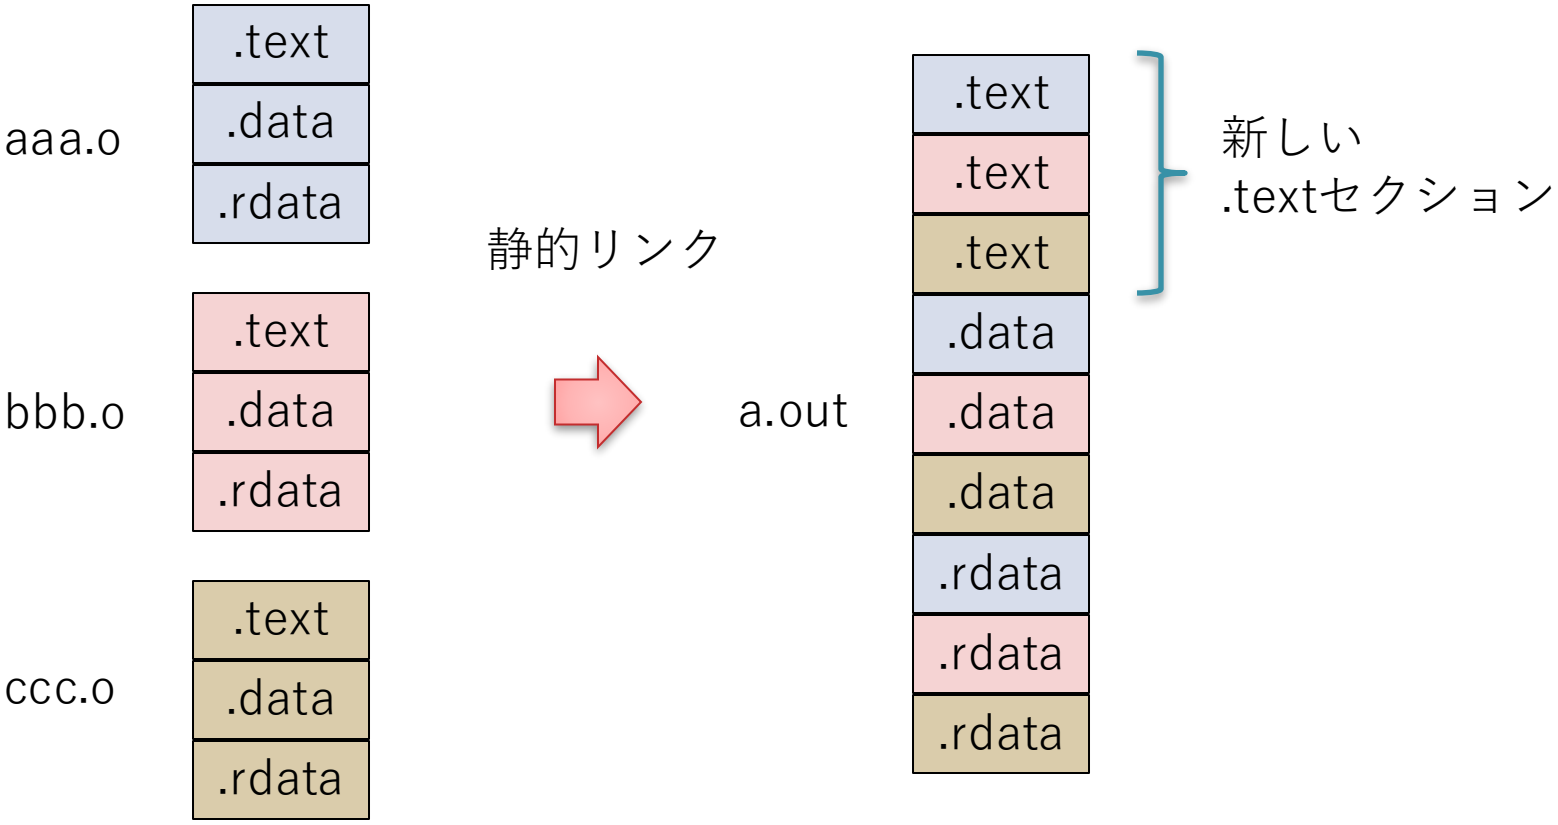

archive
記録保管所，文書局.

静的ライブラリとアーカイブ（1）

- ライブラリ
  - オブジェクトファイル(*.o)をアーカイブ形式で1つにまとめたファイル.
  - 静的ライブラリは *.a．libc.a はC標準ライブラリ.
- アーカイブ処理
  - arコマンドで，様々なアーカイブ処理を行う.

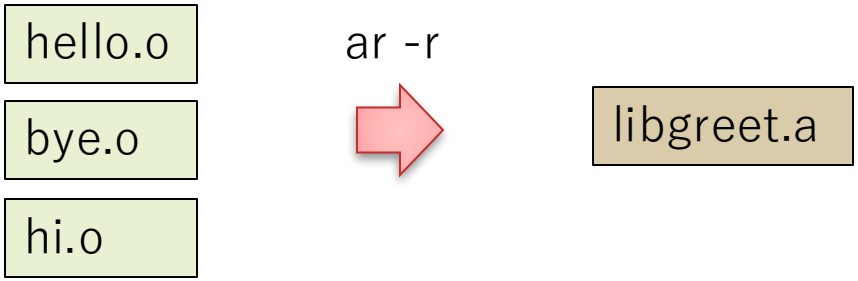

静的ライブラリとアーカイブ（2）

main.c

```
extern void hello (void);
extern void bye (void);
int main (void)
{
    hello (); bye ();
}
```

hello.c

```
#include <stdio.h>
void hello (void)
{   printf ("hello¥n"); }
```

bye.c

```
#include <stdio.h>
void bye (void)
{   printf ("bye¥n"); }
```

```
% gcc –c hello.c
% gcc –c bye.c
% ar –r libgreet.a hello.o bye.o
ar: creating archive libgreet.a
% ar –t libgreet.a
__.SYMDEF
hello.o
bye.o
% gcc main.c –lgreet –L.
% ./a.out
hello
bye
%
```

自分で作ったライブラリを呼び出せた！

-lオプションはリンクするライブラリ名を指定する．-lname で libname.a とリンクする．
-Lオプションはライブラリが存在するディレクトリを指定する．

macOS のABIを少しだけ紹介

- **Introduction to Mac OS X ABI Function Call Guide （英語）**
- **Mac OS X ABI Mach-O File Format Reference （英語）**

- どちらも正式な URL を発見できず．上は IA-32のみで，x86-64を含まず．

大きな構造体を関数から返す方法（1）

1つ目のマニュアルから転載

Listing 4: Using a large structure --- source code

```
typedef struct {
    float ary[8];
} big_struct;
big_struct callee(int a, float b) {
    big_struct callee_struct;
    ...
    return callee_struct;
}
caller () {
    big_struct caller_struct;
    caller_struct = callee(3, 42.0);
}
```

問題：大きな構造体はレジスタに入りきらない．
どうやって，引数や返り値として渡せばいいか？
スタック上に大きなサイズの引数を積む？

大きな構造体を関数から返す方法（2）

1つ目のマニュアルから転載

Listing 5: Using a large structure --- compiler interpretation

```
typedef struct {
    float ary[8];
} big_struct;
void callee(big_struct *p, int a, float b)
{
    big_struct callee_struct;
    ...
    *p = callee_struct;
    return;
}
caller() {
    big_struct caller_struct;
    callee(&caller_struct, 3, 42.0);
}
```

答え：隠し引数としてポインタを渡す
（ようなアセンブリコードを生成する）.
callerとcalleeで合意が取れていればOK